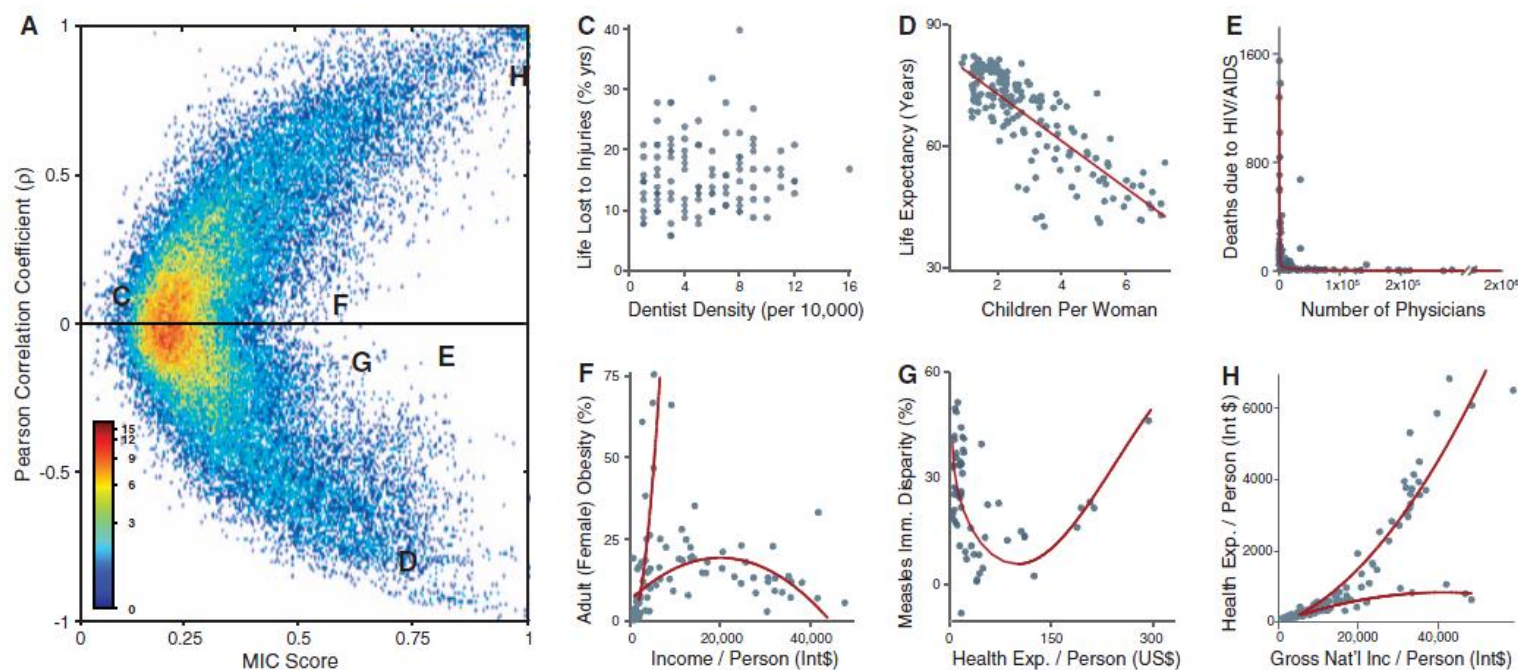


## 数据分析与R语言 第6周

2012.6.12

# 传统回归模型的困难

- 为什么一定是线性？或某种非线性模型？
- 过分依赖于分析者的经验
- 对于非连续的离散数据难以处理



2012.6.12

- 《Science》上的文章《Detecting Novel Associations in Large Data Sets》
- 方法概要：用网格判断数据的集中程度，集中程度意味着是否有关联关系
- 方法具有一般性，即无论数据是怎样分布的，不限于特定的关联函数类型，此判断方法都是有效
- 方法具有等效性，计算的熵值和噪音的程度有关，跟关联的类型无关
- MIC : the Maximal Information Coefficient
- MINE : Maximal Information-based Nonparametric Exploration



# MIC值计算

- 坐标平面被划分为(x,y)网格G (未必等宽) , 其中 $xy < n^{0.6}$
- 在G上可以诱导出“自然概率密度函数”  $p(x,y)$  , 任何一个方格 ( box ) 内的概率密度函数值为这个方格所 包含的样本点数量占全体样本点的比例
- 计算网格划分G下的 **mutual information值**  $I_G$

$$I(X; Y) = \int_Y \int_X p(x, y) \log \left( \frac{p(x, y)}{p(x)p(y)} \right) dx dy.$$

# MIC值计算

- 构造**特征矩阵** $\{m_{xy}\}$ ，矩阵的元素 $m_{xy} = \max\{I_G\} / \log \min\{x, y\}$ 。max取遍所有可能的(x,y)网格G
- $MIC = \max \{m_{xy}\}$ 。Max取遍所有可能的(x,y)对



- Mxy的计算是个难点，数据科学家构造了一个近似的逼近算法以提高效率

<http://www.sciencemag.org/content/suppl/2011/12/14/334.6062.1518.DC1>


在作者的网站上，可以下载MINE计算MIC的程序（Java和R）以及测试用数据集

<http://www.exploredata.net/Downloads>

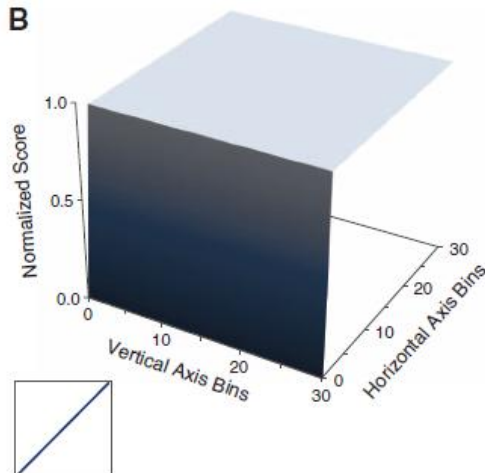
实验：WHO数据集，全球数据集...

- 如果变量对 $x, y$ 存在函数关系，则当样本数增加时，MIC必然趋向于1
- 如果变量对 $x, y$ 可以由参数方程 $c(t) = [x(t), y(t)]$ 所表达的曲线描画，则当样本数增加时，MIC必然趋于1
- 如果变量对 $x, y$ 在统计意义下互相独立，则当样本数增加时，MIC趋于0


A




B




C




D



E




F



2012.6.12




# MIC与线性回归模型对比



2012.6.12

# 对基因数据集spellman的探索

- 数据集包含6223组基因数据
- MINE对关联关系的辨认力明显强于以往的方法，例如双方都发现了HTB1，但MINE方法挖出了过去未被发现的HSP12



2012.6.12

# 数据挖掘：关联规则挖掘

## ■ 例子：购物篮分析



2012.6.12

- 挖掘数据集：购物篮数据
- 挖掘目标：关联规则
- 关联规则：牛奶=>鸡蛋【支持度=2%，置信度=60%】
- 支持度：分析中的全部事务的2%同时购买了牛奶和鸡蛋
- 置信度：购买了牛奶的筒子有60%也购买了鸡蛋
- 最小支持度阈值和最小置信度阈值：由挖掘者或领域专家设定



2012.6.12

- 项集：项（商品）的集合
- k-项集：k个项组成的项集
- 频繁项集：满足最小支持度的项集，频繁k-项集一般记为 $L_k$
- 强关联规则：满足最小支持度阈值和最小置信度阈值的规则

# 关联规则挖掘路线图

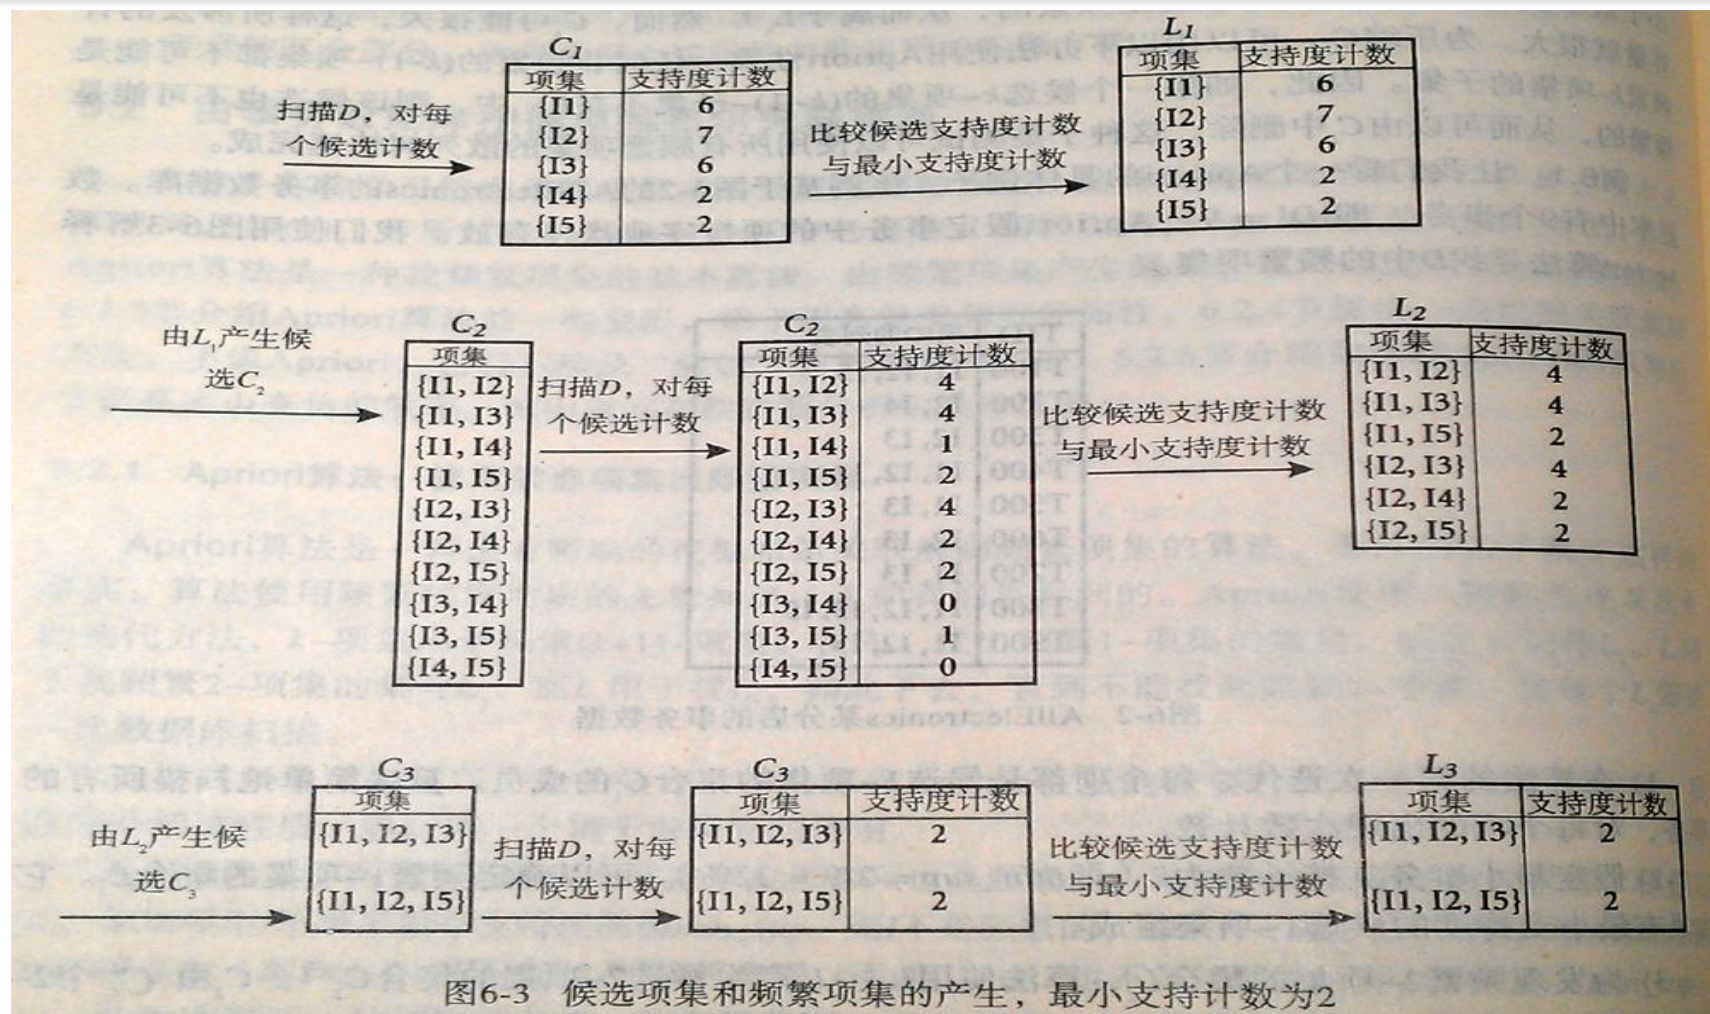
- 两步过程：找出所有频繁项集；由频繁项集产生强关联规则
- 算法：Apriori
- 例子

TID	项ID的列表
T100	I1, I2, I5
T200	I2, I4
T300	I2, I3
T400	I1, I2, I4
T500	I1, I3
T600	I2, I3
T700	I1, I3
T800	I1, I2, I3, I5
T900	I1, I2, I3

图6-2 AllElectronics某分店的事务数据



# Apriori算法的工作过程



2012.6.12

## 步骤说明

- 扫描D，对每个候选项计数，生成候选1-项集C1
- 定义最小支持度阈值为2，从C1生成频繁1-项集L1
- 通过L1xL1生成候选2-项集C2
- 扫描D，对C2里每个项计数，生成频繁2-项集L2
- 计算L3xL3，利用apriori性质：频繁项集的子集必然是频繁的，我们可以删去一部分项，从而得到C3，由C3再经过支持度计数生成L3
- 可见Apriori算法可以分成 **连接，剪枝** 两个步骤不断循环重复



## 由频繁项集提取关联规则

- 例子：我们计算出频繁项集{I1,I2,I5}，能提取哪些规则？

$I1 \wedge I2 \Rightarrow I5$ ，由于{I1,I2,I5}出现了2次，{I1,I2}出现了4次，故置信度为 $2/4 = 50\%$

类似可以算出

$I1 \wedge I2 \Rightarrow I5,$	$confidence = 2/4 = 50\%$
$I1 \wedge I5 \Rightarrow I2,$	$confidence = 2/2 = 100\%$
$I2 \wedge I5 \Rightarrow I1,$	$confidence = 2/2 = 100\%$
$I1 \Rightarrow I2 \wedge I5,$	$confidence = 2/6 = 33\%$
$I2 \Rightarrow I1 \wedge I5,$	$confidence = 2/7 = 29\%$
$I5 \Rightarrow I1 \wedge I2,$	$confidence = 2/2 = 100\%$

- 安装arules包并加载
- 内置Groceries数据集

`library(arules)` #加载arules程序包

`data(Groceries)` #调用数据文件

`Inspect(Groceries)` #观看数据集里的数据

```
specialty bar}  
9823 {yogurt,  
      long life bakery product}  
9824 {pork,  
      frozen vegetables,  
      pastry}  
9825 {ice cream,  
      long life bakery product,  
      specialty chocolate,  
      specialty bar}  
9826 {chicken,  
      hamburger meat,  
      citrus fruit,
```

## ■ 求频繁项集

```
frequentsets=eclat(Groceries,parameter=list(support=0.05,maxlen=10))
```

```
parameter specification:
```

```
tidLists support minlen maxlen          target    ext
      FALSE   0.05      1      10 frequent itemsets FALSE
```

```
algorithmic control:
```

```
sparse sort verbose
      7    -2     TRUE
```

```
eclat - find frequent item sets with the eclat algorithm
version 2.6 (2004.08.16)          (c) 2002-2004    Christian Borgelt
create itemset ...
set transactions ...[169 item(s), 9835 transaction(s)] done [0.00s].
sorting and recoding items ... [28 item(s)] done [0.00s].
creating sparse bit matrix ... [28 row(s), 9835 column(s)] done [0.00s].
writing ... [31 set(s)] done [0.02s].
Creating S4 object ... done [0.00s].
```

## ■ 观看频繁项集

```
inspect(frequentsets[1:10])
```

```
inspect(sort(frequentsets,by="support")[1:10]) #根据支持度对求得的频繁项集排序  
并察看
```

	items	support
1	{whole milk}	0.25551601
2	{other vegetables}	0.19349263
3	{rolls/buns}	0.18393493
4	{soda}	0.17437722
5	{yogurt}	0.13950178
6	{bottled water}	0.11052364
7	{root vegetables}	0.10899847
8	{tropical fruit}	0.10493137
9	{shopping bags}	0.09852567
10	{sausage}	0.09395018

## ■ 利用apriori函数提取关联规则

```
rules=apriori(Groceries,parameter=list(support=0.01,confidence=0.5))
```

```
> rules=apriori(Groceries,parameter=list(support=0.01,confidence=0.5))
```

```
parameter specification:
```

confidence	minval	smax	arem	aval	originalSupport	support	minlen	maxlen	target	ext
0.5	0.1	1	none	FALSE	TRUE	0.01	1	10	rules	FALSE

```
algorithmic control:
```

filter	tree	heap	memopt	load	sort	verbose
0.1	TRUE	TRUE	FALSE	TRUE	2	TRUE

```
apriori - find association rules with the apriori algorithm
version 4.21 (2004.05.09) (c) 1996-2004 Christian Borgelt
set item appearances ...[0 item(s)] done [0.00s].
set transactions ...[169 item(s), 9835 transaction(s)] done [0.00s].
sorting and recoding items ... [88 item(s)] done [0.00s].
creating transaction tree ... done [0.02s].
checking subsets of size 1 2 3 4 done [0.00s].
writing ... [15 rule(s)] done [0.00s].
creating S4 object ... done [0.00s].
```

## ■ 列出关联规则

summary(rules) #察看求得的关联规则之摘要

inspect(rules)

```
> inspect(rules)
```

	lhs	rhs	support	confidence	lift
1	{curd, yogurt}	=> {whole milk}	0.01006609	0.5823529	2.279125
2	{other vegetables, butter}	=> {whole milk}	0.01148958	0.5736041	2.244885
3	{other vegetables, domestic eggs}	=> {whole milk}	0.01230300	0.5525114	2.162336
4	{yogurt, whipped/sour cream}	=> {whole milk}	0.01087951	0.5245098	2.052747
5	{other vegetables, whipped/sour cream}	=> {whole milk}	0.01464159	0.5070423	1.984385
6	{pip fruit, other vegetables}	=> {whole milk}	0.01352313	0.5175097	2.025351
7	{citrus fruit, root vegetables}	=> {other vegetables}	0.01037112	0.5862069	3.029608
8	{tropical fruit, root vegetables}	=> {other vegetables}	0.01230300	0.5845411	3.020999
9	{tropical fruit,				

2012.6.12

## 用 R 进行购物篮分析

### ■ 按需要筛选关联规则

```
x=subset(rules,subset=rhs%in%"whole milk"&lift>=1.2)  #求所需要的关联规则子集
```

```
inspect(sort(x,by="support")[1:5])  #根据支持度对求得的关联规则子集排序并察看
```

其中  $lift = P(L,R)/(P(L)P(R))$  是一个类似相关系数的指标。 $lift=1$ 时表示L和R独立。这个数越大，越表明L和R存在在一个购物篮中不是偶然现象。

# 购物篮分析的应用

- 超市里的货架摆设设计
- 电子商务网站的交叉推荐销售

购买本商品的顾客还买过



时间序列分析及应  
用 R语言  
¥ 36.00

- R语言数据操作
- R语言与统计分析
- 多元统计分析及R语言建
- R语言初学者指南
- 统计模拟及其R实现
- 线性模型引论
- 时间序列分析：方法与应
- MATLAB统计分析与应用：
- 金融时间序列分析 (第2版)

更多>>

## 统计建模与R软件

正在读 (6人)，已读过



分享到：新浪微博 | 腾讯微博 | 开心网 | 人人网

满额打折 十万种大中专教材/教参满59折上98折，满199折上9  
详情>>

当 当 价：¥ 34.30

定 价：¥ 49.00 折扣：70折

顾客评分：★★★★★ 已有98人评论

库 存：送至 广东 有货

作 者：薛毅，陈立萍 编著

出 版 社：清华大学出版社

出版时间：2007-4-1

版 次：1 页 数：525 字

印刷时间：2007-4-1 开 本： 纸

印 次： I S B N：9787302143666 包

2012.6.12



**货到付款的客户注意：**如果有客户想选择货到付款的，拍下商品后，请一定要与旺旺客服联系。如果拍下来，不与旺旺客服联系，在48小时内我们会关闭交易。

浏览了该宝贝的会员还浏览了



754之顶级经典 全新 华硕  
K8V-mx 带集成显卡 带AGP

¥ 116.00



478 865PE 豪华大板  
GA-8IPE1000-G 集声和

¥ 108.00



英特尔915G D915GAG 全集  
128显卡 千兆网卡

¥ 85.00



特价75元 技嘉845GV  
GA-8I845GV 板载声显网卡 支

¥ 100.00

# 购物篮分析的应用

## ■ 网站或节目的阅读/收听推荐

新浪视频 > 视频新闻 > 体育视频 > 正文

视频集锦-开场失球孔卡梅开二度 恒大2-1逆转申鑫

<http://www.sina.com.cn/> 2012年03月11日21:53 新浪体育



新浪体育 V

所属专题: 2012中超第01轮视频点播

相关视频

热点视频

你可能喜欢




视频: 实拍女子遇强敌要赖倒地反被后车...

2,681,273



视频集锦-罗宾侠乱舞闪电袭击带刀侍卫...

758,906



视频: 丰满女模穿丁字裤T台秀透视装

5,200,558



视频-13日官方10佳球 林书豪铁帽MVP邓...

1,244,842



视频集锦-林书豪15+8难敌罗斯32+7+6 尼...

843,283



视频集锦-格里芬生猛空接KG老当益壮 绿...

661,920



视频-林书豪15+8+3实录 铁帽送状元+妙...



视频-罗斯遭书豪妙传调戏 臂下被生穿身...



视频: 春光频现 实拍嫩模宽衣解带下水...

2012.6.12



# Thanks

## FAQ时间